UE 2

Fachgebiet Architektur eingebetteter Systeme Rechnerorganisation 2 Komplement, IEEE754



Alle Aufgaben, die durch ein sekennzeichnet sind, sind für die eigenständige Vor- bzw. Nachbereitung der Übung und zur Klausurvorbereitung gedacht. Sie werden in der Regel nicht von den Übungsleitern behandelt, können aber ggf. während des Tutoriums selbständig unter Anleitung des Tutors bearbeitet werden, sofern ausreichend Zeit zur Verfügung steht.

2.1 Binäroperationen

Gegeben sei folgender C-Code:

```
o int calculate (int a, int b){

1
2    int sum = a + b;
3    int diff = b - a;
4
5    int prod = a * diff;
6    int quot = b / diff;
7
8    return (sum + prod + quot);
9 }
```

Die Übergabeparameter enthalten die Werte: a = 13 und b = 20.

- 1. Wandeln Sie die gegebenen Werte von a und b in vorzeichenlose 8-Bit Dualzahlen um.
- 2. Berechnen Sie nun den Rückgabewert der Funktion. Führen Sie alle Operationen im Binären aus.

Hinweis zu Gleitpunktzahlen

Im IEEE 754-Standard existieren zwei Grundformate:

- einfache Genauigkeit (*single precision*) mit **32bit**: 1 Bit Vorzeichen, 8 Bit transformierter Exponent, 23 bit Nachkommastellen
- **doppelte Genauigkeit** (*double precision*) mit **64bit**: 1 bit Vorzeichen, 11 bit transformierter Exponent, 52 bit Nachkommastellen

Zusätzlich dazu verwenden wir in der Vorlesung und Übung das Format

• Minifloat mit 16bit: 1 bit Vorzeichen, 5 bit Exponent, 10 bit Nachkommastellen

Für die Bildung des Exponenten gilt bei diesem Sonderformat:

$$Bias = \frac{2^5}{2} - 1 = 15$$

Bei allen Aufgaben ist stets angegeben, welches IEEE 754- Format genutzt werden soll.

Zum Bias: dieser wird auf den Exponenten addiert, um stets einen positiven Exponenten zu garantieren. Dadurch können Zahlen einfach durch Betrachtung des Vorzeichenbits (positive/negative Zahl) und durch Dualzahlenvergleiche des Exponenten sortiert werden.

2.2 Konvertierung

Gegeben sind die folgenden Zahlen in dezimaler Darstellung und in der Darstellung als Minifloat nach IEEE 754.

- 1. Sortieren Sie die IEEE 754 Zahlen durch Betrachtung von Vorzeichen und Exponent ihrer Größe nach.
- 2. Wandeln Sie alle Zahlen in die jeweils andere Darstellung um. Geben Sie dabei alle Zahlen auch in halblogarithmischer Form, d.h. in der mathematischen Mantisse-Exponenten-Schreibweise, an.
- a) $6,755_{10}$
- b) 9,51178₁₀
- c) $-4,1875_{10}$
- d) 1 01100 10101010
- e) 0 10011 0110110110
- f) 1 10010 1000110011

2.3 Addition

Gegeben sind die drei Zahlenpaare

- 1. 101.0111101100_2 (5, 474609375_{10}) und 11000.1000010100_2 (24, 51757815_{10})
- 2. $1.1110110111 \cdot 2^3 (15, 43_{10})$ und $1.1010110010 \cdot 2^5 (53, 569_{10})$
- 3. $\boxed{0}$ 10010 0001101001 (8,8203125₁₀) und $\boxed{0}$ 10001 0111110000 (5,9375₁₀)

mit ihren in Klammern stehenden dezimalen Entsprechungen.

Addieren Sie diese Paare mittels Gleitpunktarithmetik.

Wandeln Sie die Ergebnisse wieder in die Dezimaldarstellung um und vergleichen Sie sie mit den tatsächlichen Ergebnissen.

Bei welchen Zahlenkombinationen treten Genauigkeitsverluste auf und wie begründen Sie das?

2.4 Multiplikation

Multiplizieren Sie folgende Zahlen mittels Gleitpunktarithmetik:

- 1. $1.1011 \cdot 2^3$ und $1.00100001 \cdot 2^4$
- 2. $1.10001100101_2 \cdot 2^5$ (6, 197265625_{10}) und $1.010000000000_2 \cdot 2^1$ (2, 5_{10})
- 3. $1.01111_2 \cdot 2^{-4} (0.091796875_{10})$ und $1.11011101_2 \cdot 2^4 (29.8125_{10})$